

프로젝트 계획서

1. 팀 정보

팀명 : IROL

팀원 : 민동규(1102545008), 정재훈(1102545010)

연락 채널 : 카카오톡

GitHub Repo : https://github.com/hoon001218/long_horizon_task_breakdown.git

2. 프로젝트 개요

프로젝트 제목 : Multimodal LLM 기반 로봇의 Long-horizon Task 분해 및 Semantic Similarity 매칭을 통한 적응형 재계획(Adaptive Re-planning) 프레임워크

2-1. 해결하려는 문제 (Problem Statement)

- 추상적 명령과 구체적 실행 간의 간극: 자연어로 주어지는 복잡한 명령(Long-horizon Task)을 로봇이 수행 가능한 최소 단위의 동작(Atomic Action)으로 변환하는 데 한계가 있음.
- 동작 자산의 불일치: 모델이 생성한 행동 명령이 로봇이 실제로 보유한 스킬 리스트에 존재하지 않을 경우 시스템이 중단되는 문제 발생.
- 동적 환경 대응력 부재: 초기 계획이 빗나가거나 실행 중 오류가 발생했을 때, 이를 스스로 인지하고 수정하는 피드백 루프가 부족함.

2-2. 왜 MLLM으로 해결해야 하는가?

- 계층적 추론 능력: 방대한 데이터를 학습한 LLM은 복잡한 과업을 논리적인 하위 단계로 분해하는 데 효과적인 성능을 보임.
- Vision-Language Grounding: VLM은 카메라 이미지 정보를 텍스트와 정렬하여, 현재 로봇의 상태와 주변 환경을 반영한 상황 인지 기반의 계획 수립이 가능함.
- 유연한 의미론적 매핑: 고정된 키워드 매칭이 아닌, 임베딩 공간 내 Semantic Similarity를 활용하여 비정형 명령을 가장 적합한 로봇 동작으로 연결할 수 있음.

2-3. 프로젝트 목표 (3가지)

① Task Decomposition 논리적 타당성 90% 달성

지표: 10단계 이상의 복합 명령에 대해 MLLM이 생성한 시퀀스가 논리적으로 결함이 없는지 검증.

측정: 자체 구축한 벤치마크 데이터셋(명령-정답 시퀀스 쌍)에 대해 전문가 평가 및 LLM-as-a-Judge 방식으로 정확도 측정.

② Semantic Alignment 정밀도 0.9 (Cosine Similarity) 이상

지표: LLM이 제안한 동작과 실제 Skill Library 간의 의미론적 유사도.

측정: 임베딩 모델을 통해 매칭된 결과가 의도된 Atomic Action과 일치하는지 확인하며, 유사도 점수 0.9 이상을 목표로 함.

③ 피드백 기반 Re-planning 성공률 80% 달성

지표: 매칭 불가능한 명령이나 모호한 상황을 입력했을 때, 시스템이 스스로 오류를 인지하고 계획을 수정하여 유효한 시퀀스를 다시 생성하는 비율.

측정: 예외 케이스(Out-of-library commands) 입력 시 재플래닝 시도 및 성공 횟수 카운트.

3. 기술 스택

- 언어: Python 3.10+
- API/모델: MLLM: GPT-4o (API) 또는 LLaVA / Llama-3-8B (로컬 추론)
- Embedding: Sentence-BERT (SBERT) 또는 OpenAI Embedding
- 데이터 및 검증: Vector DB: Faiss (Atomic Action 라이브러리 저장 및 검색)
- Logic: Pydantic (Structured Output 및 데이터 검증용)
- 프레임워크: LangChain / LangGraph (고도화된 피드백 루프 및 상태 관리)
- 인프라 (RTX 3090 2대):
 - Server A: 로컬 LLM/VLM 추론 엔진 (Ollama/vLLM)
 - Server B: Embedding 서버 및 전체 시스템 파이프라인 관리

4. 주차별 개발 계획

- 11주차: 로봇의 가용 동작 리스트(Atomic Actions)를 정의하고, RTX 3090 서버에 로컬 MLLM 추론을 위한 vLLM/Ollama 환경을 구축합니다.
- 12주차: 자연어 명령을 계층적 단계로 분해하는 Prompt Engineering과 시각 정보를 통해 환경 상태를 파악하는 상황 인지 모듈을 개발합니다.
- 13주차: 임베딩 모델과 Faiss를 활용하여 생성된 계획과 실제 동작 리스트 간의 Semantic Similarity 매칭 시스템을 구현합니다.
- 14주차: 매칭 실패 시 오류를 피드백하여 LLM이 스스로 계획을 수정하도록 유도하는 Closed-loop Re-planning 로직을 완성합니다.
- 15주차: 설정한 시나리오별 과업 성공률 및 매칭 정확도를 정량적으로 측정하고 최종 시스템의 추론 성능을 검증합니다.

5. 평가지표 & 기준선

- 정량 지표:
 - 과업 성공률(Success Rate): 전체 시퀀스 논리 결함 여부 및 최종 목적 달성률
 - 매칭 정확도(Semantic Accuracy): 생성된 동작과 Atomic Action 간의 올바른 매핑 비율

- 응답 시간(Latency): 명령어 입력부터 최종 시퀀스 생성 및 매칭 완료까지의 소요 시간
- 비교 기준선(Baseline) 설정:
 - Exact Matching: 의미론적 유사도 검사 없이 단순 키워드 매칭을 적용한 모델과의 성능 비교
 - Zero-feedback: Re-planning 루프가 없는 단방향(Open-loop) 생성 모델과의 에러 회복력 비교
- 성공 기준 정의:
 - 최소 목표: 과업 성공률 75% 이상 및 매칭 정확도 90% 이상 달성
 - 이상 목표: 복합 예외 상황에서의 Re-planning 성공률 80% 상회 및 전체 지연 시간 2초 이내 최적화

6. 참고 자료 & AI 활용

핵심 논문 (arXiv 링크):

- Code as Policies: Language Model Programs for Embodied Control (arXiv:2209.07753)
- SayCan: Do As I Can, Not As I Say: Grounding Language Models in Robotic Affordances (arXiv:2204.01691)
- Inner Monologue: Embodied Reasoning through Planning with Language Models (arXiv:2207.05608)

AI 활용 계획:

- GPT-4o/Gemini: 시스템 아키텍처 설계 및 Long-horizon 과업 분해를 위한 고도화된 프롬프트 설계 보조.
- Claude 3.5 Sonnet: 복잡한 알고리즘 구현 코드(Similarity Matching, Re-planning Logic) 작성 및 디버깅.
- Local Llama-3/LLaVA: 프로젝트의 핵심 추론 엔진으로 활용하여 RTX 3090 기반의 로컬 실행 환경 구축.

AI 사용 로그 관리 방법:

- Prompt History: 사용된 주요 프롬프트와 생성된 결과물을 Notion 페이지에 기록하여 버전별 성능 변화 모니터링.
- Git Commit Message: AI를 통해 생성되거나 수정된 코드는 커밋 메시지에 'AI-assisted' 태그를 명시하여 변경 이력 관리.